

Técnicas de Inteligencia Artificial

Tema 1. Introducción

Índice

Esquema

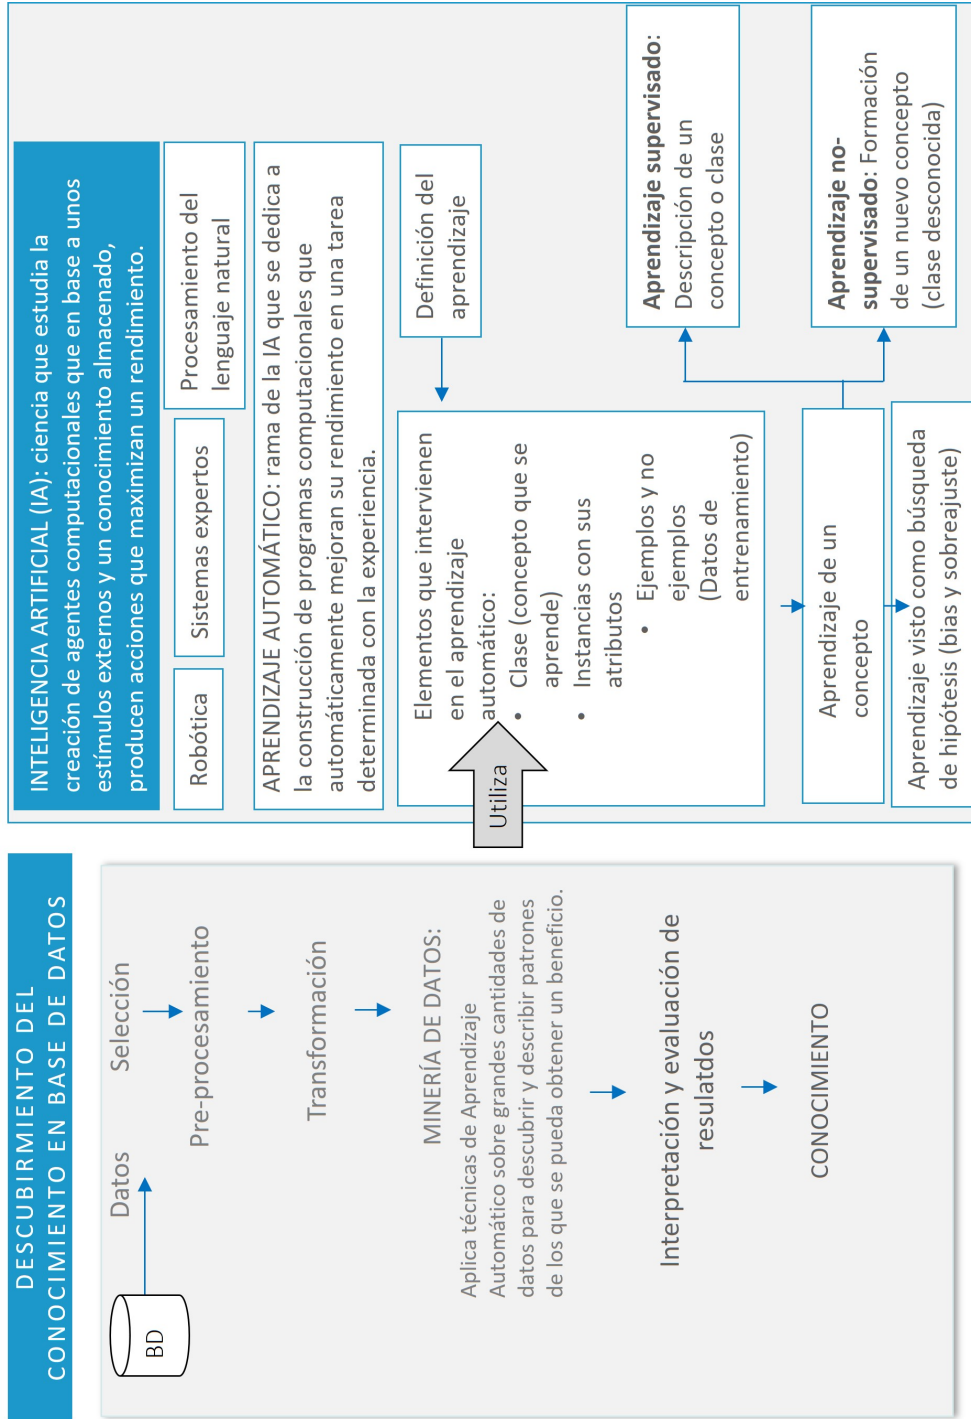
Ideas clave

- 1.1. ¿Cómo estudiar este tema?
- 1.2. Aproximación a los conceptos de inteligencia artificial, aprendizaje automático y minería de datos. Interés y aplicaciones
- 1.3. Definición de aprendizaje, tareas básicas y ejemplos
- 1.4. Etapas en el descubrimiento de conocimiento
- 1.5. Referencias bibliográficas

A fondo

- Introducción e historia de la inteligencia artificial
- Entrevista a Matilde Santos Peñas sobre la inteligencia artificial
- Conciencia artificial y test de Turing
- Inteligencia artificial
- Presentación introductoria de la minería de datos
- AI Topics

Test



1.1. ¿Cómo estudiar este tema?

Para estudiar este tema deberás leer las **Ideas clave** que se presentan a continuación. Puedes completar el estudio visualizando la lección magistral, revisando referencias y bibliografía, así como accediendo a los recursos adicionales que se facilitan.

Al comienzo de este tema se describen a alto nivel los conceptos de **inteligencia artificial** y también de la **minería de datos** (Han & Kamber, 2012; Negnevitsky, 2005), la cual aplica técnicas de aprendizaje automático (subrama de la inteligencia artificial) para extraer conocimiento útil de *data warehouses*, *data lakes* (Khine & Wang, 2018) o bases de datos más sencillas. Muestra además la importancia de estos campos y su gran diversidad de aplicaciones.

A continuación, se explican conceptos fundamentales del **aprendizaje automático**: definición de aprendizaje, elementos que intervienen en una tarea de aprendizaje, diversos tipos de aprendizaje acompañados de ejemplos, etc., (Mitchell, 1997; Witten & Frank, 2005). Todos ellos son conceptos importantes en esta asignatura, los cuales aparecerán repetidamente en temas posteriores junto con otros como datos de entrenamiento, instancias, clases, *bías* o sobreajuste.

Al finalizar el tema se describen los pasos de un proceso típico de **descubrimiento de conocimiento en bases de datos**, uno de los cuales consiste precisamente en la aplicación de un proceso de minería de datos para extraer patrones de los datos.

Al finalizar el estudio de este tema serás capaz de:

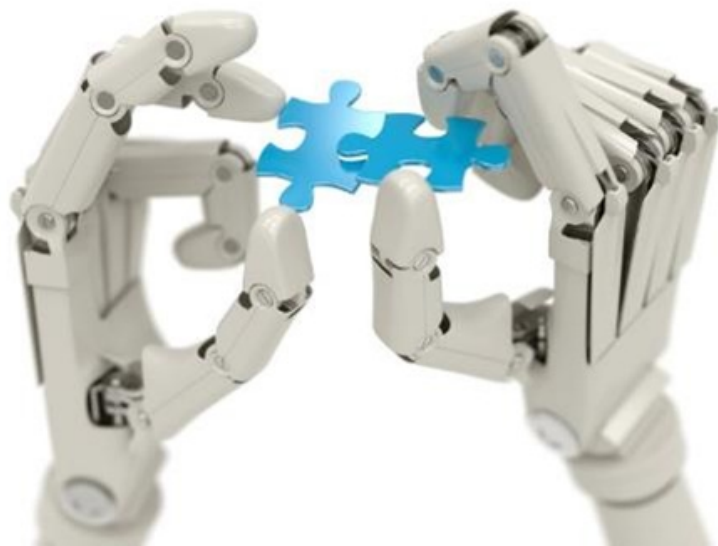
- ▶ Distinguir los conceptos de inteligencia artificial, aprendizaje automático y minería de datos, identificar su interés y posibles aplicaciones.
- ▶ Definir el aprendizaje automático y tareas básicas de descripción o formación de conceptos.
- ▶ Definir los elementos que intervienen en el aprendizaje de conceptos.
- ▶ Identificar las etapas que comprenden el diseño de un sistema de aprendizaje.
- ▶ Identificar las etapas de un procedimiento típico de descubrimiento de conocimiento en bases de datos.

1.2. Aproximación a los conceptos de inteligencia artificial, aprendizaje automático y minería de datos. Interés y aplicaciones

En el Diccionario de la Lengua Española de la Real Academia Española podemos encontrar la siguiente **definición de Inteligencia Artificial (IA)** (ASALE & RAE, s. f.): «Disciplina científica que se ocupa de crear programas informáticos que ejecutan operaciones comparables a las que realiza la mente humana, como el aprendizaje o el razonamiento lógico». Estas operaciones y procesos de la inteligencia humana son los necesarios para el aprendizaje, la comprensión, la resolución de problemas o la toma de decisiones. Por tanto, la inteligencia artificial es una disciplina amplia que reúne varios campos como el aprendizaje automático, los sistemas expertos, sistemas RPA (*Robotic Process Automation*), la robótica o los sistemas de procesamiento de lenguaje natural.

El objetivo de la IA, desde el punto de vista de la investigación y de la ciencia, es comprender los principios que hacen posible el comportamiento inteligente en sistemas artificiales. Para ello, se deben analizar agentes naturales y artificiales, formular y testear hipótesis sobre lo que implica construir un sistema artificial que realice tareas que requieren inteligencia, así como diseñar y desarrollar el sistema inteligente empírico, esto es, experimentando y comprobando las distintas hipótesis planteadas (Poole & Mackworth, 2010).

Existe mucha controversia y debate sobre si las máquinas pueden ser inteligentes y pensar. Una afirmación interesante es la que se puede encontrar en (Poole & Mackworth, 2010) donde el autor indica que «se puede considerar una máquina inteligente si actúa de manera inteligente, creando inteligencia real de una manera artificial o no natural». Igualmente, de acuerdo a Negnevitsky (Negnevitsky, 2005), una máquina es considerada inteligente si puede conseguir un rendimiento igual al de un humano en una tarea cognitiva.



En gran parte de los libros de inteligencia artificial, cuando se habla de la historia de esta ciencia y sobre el debate del pensamiento artificial en las máquinas, se hace referencia al artículo de **Alan Turing** con título «Computing machinery and intelligence» publicado en el año 1950 (Turing, 1950). Este es uno de los artículos más relevantes y antiguos sobre la inteligencia de las máquinas.

Turing definió el comportamiento inteligente de un ordenador como la «habilidad de conseguir un rendimiento similar al de un humano en tareas cognitivas». Turing propone un juego de imitación en el que un juez humano debe interrogar a otro humano y a un ordenador remotamente y conseguir adivinar quién es el ordenador de sus dos interlocutores. Para que el ordenador no sea descubierto debe, por tanto, responder como un humano lo haría, hacer cálculos con la rapidez de un humano, titubear e incluso enfadarse si las preguntas son provocadoras.

A modo de curiosidad, según la referencia (Ohlsson *et al.*, 2017), la inteligencia artificial ha alcanzado en este sentido el nivel de un niño de 4 años. En la práctica no es habitual la creación de programas con el objetivo de que se comporten intelectualmente como humanos, sino que **se buscan programas que ayuden a las personas a procesar grandes cantidades de datos, tomar decisiones o realizar cálculos rápidos**. Sin embargo, aunque en principio no parezca completamente útil imitar el comportamiento humano, el test de Turing sienta precisamente las bases de un método de validación de sistemas expertos que consiste en la comparación del rendimiento del sistema inteligente con el del rendimiento de varios humanos expertos en una determinada área de conocimiento.

En esta asignatura no se estudia la IA desde un punto de vista teórico o científico, sino desde el punto de vista práctico de la ingeniería. A continuación, se plantea una definición funcional y pragmática de esta ciencia:

Inteligencia artificial

Es una rama de la informática que estudia la creación de agentes computacionales que reciben estímulos externos y, en base a ellos y a un **conocimiento** almacenado en dicho agente, producen resultados o acciones que **maximizan una medida de rendimiento**. El conocimiento almacenado puede ser aprendido por el mismo agente utilizando técnicas de aprendizaje automático o puede ser incorporado por un humano experto en el dominio específico.

En este sentido, y en relación con los **grandes conjuntos de datos (*Big Data*)**, es de gran interés el campo de la **Minería de Datos**, cuyo objetivo es eminentemente práctico.

Minería de datos

Es un proceso que utiliza técnicas de inteligencia artificial sobre grandes cantidades de datos con el objetivo de descubrir y describir patrones en los datos, a partir de los cuales se pueda obtener un beneficio.

Las fuentes de datos pueden incluir bases de datos, *data warehouses*, *data lakes*, repositorios o información en la web. Las técnicas que en concreto utiliza la minería de datos son esencialmente las denominadas técnicas de **aprendizaje automático**.

El **aprendizaje automático**, una rama de la IA, se refiere a la construcción de programas computacionales que automáticamente mejoran su rendimiento en una tarea determinada con la experiencia.

Así, la minería de datos utiliza técnicas de aprendizaje automático para, por ejemplo, aprender a detectar el uso fraudulento de tarjetas de crédito. A partir de datos de experiencias previas de usos fraudulentos y no fraudulentos de tarjetas de crédito, mediante la aplicación iterativa de técnicas de aprendizaje automático, se puede mejorar en la tarea de detectar usos fraudulentos.

Por otra parte, el aprendizaje automático tiene múltiples aplicaciones en otro tipo de

sistemas como en aquellos relacionados con la robótica, o en sistemas de reconocimiento de habla, por ejemplo (Rogers & Girolami, 2017). En el siguiente apartado se explican conceptos relacionados con el aprendizaje automático que serán de gran interés y uso a lo largo de la asignatura.

En la Figura 1 podemos ver las diferentes ramas de la inteligencia artificial y el espacio que ocupa en dicha taxonomía el aprendizaje automático o *machine learning*, así como sus diferentes subramas.

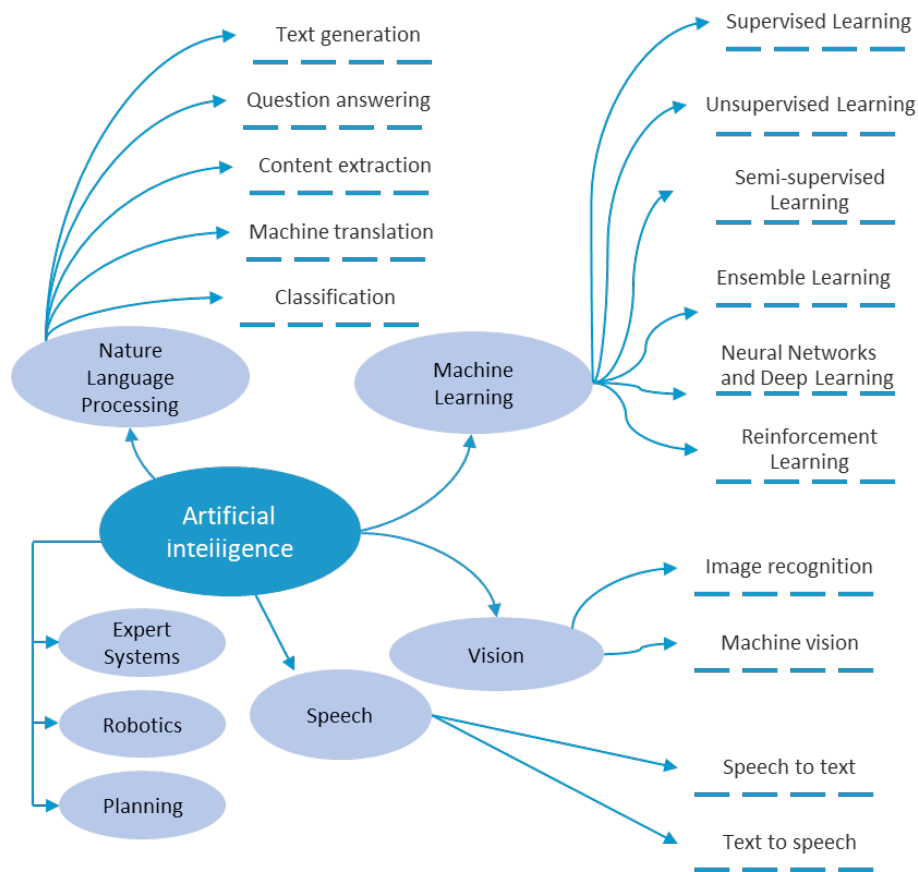


Figura 1. Taxonomía del machine learning dentro de la Inteligencia Artificial. Basado en Panesar, 2019.

Interés y aplicaciones de la inteligencia artificial

La inteligencia artificial tiene aplicaciones innumerables en diversas áreas tales como la robótica, los juegos de ordenador, el *marketing*, la medicina, o la predicción meteorológica (Pannu, 2015).

De hecho, hay muy diversos tipos de problemas que pueden ser resueltos por sistemas inteligentes, como los que se enumeran a continuación:

- ▶ **Diagnosis:** inferir funcionamientos incorrectos de un objeto a partir de su comportamiento y recomendar soluciones.
- ▶ **Selección:** recomendar la mejor opción de una lista de alternativas posibles.
- ▶ **Predicción:** predecir el comportamiento futuro de un objeto a partir de su comportamiento en el pasado.
- ▶ **Clasificación:** asignar un objeto a una clase definida.
- ▶ **Agrupamientos (*clustering*):** agrupar objetos de acuerdo con sus características.
- ▶ **Optimización:** mejorar la calidad de las soluciones hasta encontrar una óptima.
- ▶ **Control:** gestionar el comportamiento de un objeto en tiempo real para satisfacer ciertos requisitos especificados.

Específicamente, en lo que respecta a las «grandes cantidades de datos», por todos es bien conocido el crecimiento inminente de la cantidad de datos que almacenan y manejan cada vez más y más instituciones y empresas en los últimos tiempos. Aquellas organizaciones que consiguen extraer conocimiento a partir de esos datos y optimizar su aplicación son las que tienen mayor oportunidad de mantenerse

competitivas.

Por ello, dado que la necesidad es la madre de la invención, la aplicación de técnicas de inteligencia artificial a cantidades masivas de datos para su análisis automático (la minería de datos) es un campo que está en pleno auge y en constante evolución. Pueden encontrarse ejemplos de aplicación en múltiples ámbitos, como el médico, el económico-empresarial, el industrial o el marketing, entre muchos otros.

En el campo de la **medicina** se encuentran multitud de aplicaciones de las técnicas de inteligencia artificial. Por ejemplo, analizando grandes cantidades de datos sobre una enfermedad, se puede predecir el diagnóstico y pronóstico de enfermedades. Así, conociendo ciertos síntomas y características de un determinado paciente, se puede diagnosticar con bastante probabilidad una enfermedad y establecer un tratamiento óptimo para dicho paciente (Peng *et al.*, 2020).

El uso de las técnicas de inteligencia artificial en medicina está muy extendido. Dos ejemplos de enfermedades que pueden ser diagnosticadas son, por ejemplo, el Alzheimer o el glaucoma (Farooq *et al.*, 2017). Por otro lado, y como segundo ejemplo, existen sistemas inteligentes basados en heurísticas y reglas para establecer el mejor emparejamiento posible entre un donante y los posibles receptores de un trasplante (Aguado *et al.*, 2019; Namatevs & Aleksejeva, 2017).

En la **educación** también se encuentran aplicaciones de sistemas inteligentes. Los denominados sistemas tutores inteligentes tratan de emular las pautas que los tutores humanos dan para optimizar el estudio del alumno. Por ejemplo, hay sistemas inteligentes que personalizan los contenidos que se presentan al estudiante en función de su progreso en el aprendizaje o de su estilo de aprendizaje (Alonso *et al.*, 2019). También hay sistemas que analizan la solución que un estudiante da a un problema y tratan de guiarle, ofreciendo pistas y otras pautas, para que consiga resolver el problema (García *et al.*, 2015).

Otro campo donde se utilizan mucho las técnicas de inteligencia artificial, en concreto

de aprendizaje automático, es en el **marketing**, en **sistemas de gestión de clientes** (comúnmente denominados por sus siglas en inglés CRM — Customer Relationship Management) y **posicionamiento de productos** (Sterne, 2017; Zeeshan & Saxena, 2020).

La **industria**, y de forma más concreta en torno al paradigma de la **Industria 4.0**, es otro de los grandes beneficiados de la aplicación e implementación de técnicas de inteligencia artificial en sus procesos. La fabricación inteligente, el mejor uso de los datos que genera la empresa a través de sistemas *business intelligence* avanzados, o la implementación de soluciones de robótica (Narasima Venkatesh, 2018; Bayram & İnce, 2018; Cevik Onar & Ustundag, 2018; Sami Sivri & Oztaysi, 2018).

En la **gestión empresarial** también se encuentran aplicaciones inteligentes para, entre otros, la planificación eficiente de recursos o como apoyo a la toma de decisiones, por ejemplo, aquellas relacionadas con el análisis de la solvencia empresarial (Jain *et al.*, 2020; Malhotra *et al.*, 2017).

Un ejemplo que habitualmente se encuentra en los libros de IA o minería de datos es el de uso de un sistema inteligente para la toma de decisiones en lo que respecta a la concesión de préstamos (Witten & Frank, 2005).

De hecho, los bancos son de las primeras entidades que adoptaron soluciones de minería de datos con este fin. Posteriormente, los bancos han ido adoptando estas soluciones como parte de sus sistemas CRM, para el apoyo a la gestión de las relaciones con los clientes, la venta y el *marketing*. Por ejemplo, con estas técnicas, los bancos pueden modelar patrones de comportamientos de aquellos clientes que pierden para poder detectar a priori los potenciales clientes perdidos y tomar las acciones correctivas convenientes.

Por otra parte, los sistemas de comercio electrónico (como Amazon) o los proveedores de contenidos digitales (como Netflix o Spotify) pueden beneficiarse de los sistemas «recomendadores» que predicen el interés de un usuario por ciertos productos a partir de las valoraciones dadas a diversos productos por otros muchos usuarios con perfil similar (Joshi, 2020; Linden *et al.*, 2003).

También es frecuente encontrar sistemas inteligentes para el **diagnóstico y el troubleshooting**, detección de problemas y propuesta de soluciones, como por ejemplo los que tratan de detectar un fallo en una red de ordenadores y guían al administrador de la red en el proceso de diagnóstico y corrección del error, así como en los fallos de los propios ordenadores (Akinola, 2012; Elmishali *et al.*, 2018; Nushi *et al.*, 2017).

Existen también sistemas inteligentes que proporcionan **rutas óptimas**, ya sean de transporte de mercancías (Abduljabbar *et al.*, 2019; Boru *et al.*, 2019; Mohammed *et al.*, 2017) o en transmisión de datos en redes telemáticas, por ejemplo, en base a ciertos requerimientos como pueda ser la ruta de menor coste o la ruta más rápida (Mali & Gautam, 2018; Matlou & Abu-Mahfouz, 2017).

Referido al **consumo energético**, existen múltiples soluciones en las que la inteligencia artificial sirve como soporte a otros sistemas que son utilizados para reducir el consumo energético. Por ejemplo, dando soporte a la localización en tiempo real para reducir el consumo energético en edificios públicos (García *et al.*, 2017), o bien integrando localización y sensorización para fomentar el ahorro energético en hogares (Óscar García *et al.*, 2017). Igualmente, en la industria de suministro eléctrico se utilizan técnicas inteligentes para predecir la demanda de electricidad por tramos horarios. De esta manera, las compañías suministradoras pueden planificar por ejemplo acciones de mantenimiento (Jozi *et al.*, 2019, 2017; Silva *et al.*, 2020; Vinagre *et al.*, 2016).

En **meteorología** y para la predicción o gestión de catástrofes también se han utilizado sistemas inteligentes (McGovern *et al.*, 2017), así como en **agricultura** para la planificación agrícola, el control de plagas o la gestión de cultivos (Liakos *et al.*, 2018). El artículo (Alonso *et al.*, 2020) expone una solución IoT aplicada en la agricultura y la ganadería en la que se monitorizan cultivos y ganado para optimizar su producción.

Incluso se pueden encontrar ejemplos curiosos en el campo de la **arqueología**, donde la inteligencia artificial se ha utilizado recientemente para descubrir nuevos yacimientos arqueológicos (Davis, 2020; Traviglia & Torsello, 2017).

Todos estos ejemplos son solo una pequeña muestra que pretende ilustrar la gran utilidad de la aplicación de la IA en muy diversos campos.

1.3. Definición de aprendizaje, tareas básicas y ejemplos

Dado que la inteligencia se adquiere mediante la experiencia y el aprendizaje, el concepto de aprendizaje es muy importante en el campo de la inteligencia artificial, siendo precisamente muy populares las técnicas de la rama de aprendizaje automático.

La siguiente frase define el aprendizaje por parte de un ordenador:

Un programa de ordenador aprende de la experiencia E con respecto a una clase de tareas T y una medida de rendimiento P, si su rendimiento en las tareas T, medido en base a la medida P, mejora con la experiencia E. (Mitchell, 1997).

Para ilustrar esta definición y los elementos E, P y T, se exponen a continuación algunos ejemplos de tareas de aprendizaje:

Ejemplo 1: Aprender a detectar robos de tarjetas de crédito.

- ▶ T: detectar robos de tarjetas de crédito.
- ▶ P: porcentaje de robos detectados.
- ▶ E: base de datos de hábitos de compra con la tarjeta de crédito.

Ejemplo 2: Aprender a reconocer la escritura manual.

- ▶ T: reconocer y clasificar palabras escritas en imágenes.
- ▶ P: porcentaje de palabras correctamente clasificadas.
- ▶ E: base de datos de imágenes de palabras manuscritas clasificadas.

Ejemplo 3: Aprender a aparcar un coche utilizando sensores de visión.

- ▶ T: aparcar un coche utilizando sensores de visión.
- ▶ P: porcentaje de aparcamientos correctos.
- ▶ E: secuencias de imágenes y comandos de guiados registrados.

¿Qué contenidos se pueden aprender?

De acuerdo con la teoría de instrucción de Merrill denominada «Teoría de presentación de componentes», «*Component display theory*» (Merril *et al.*, 1994), **las personas pueden aprender** cuatro tipos de contenido:

- ▶ **Hechos:** simples afirmaciones de una verdad, que puede ser una asociación entre una fecha y un hecho, o un nombre y un objeto.
- ▶ **Conceptos:** conjunto de objetos, símbolos o eventos agrupados porque comparten ciertas características y que pueden ser referenciados por un nombre en particular o un símbolo. Los objetos existen en el espacio y tiempo como puede ser una persona, una mesa; los símbolos se refieren a tipos de palabras, números, marcas, como puede ser un predicado o una fracción; los eventos son interacciones específicas de objetos en un periodo de tiempo como puede ser la digestión o la fotosíntesis.
- ▶ **Procedimientos:** conjunto de acciones realizadas en pasos consecutivos para alcanzar un objetivo.
- ▶ **Principios:** relaciones causa-efecto, verdades generales o leyes básicas para afirmar otras verdades.

Específicamente, los ordenadores pueden ser muy eficaces en el **aprendizaje de conceptos** que pueden ser representados mediante distintos tipos de estructuras como árboles, reglas o funciones matemáticas, como se verá más adelante en la asignatura.

También existen sistemas del campo de la robótica, por ejemplo, cuyo objetivo es aprender un procedimiento. Estos sistemas tratan de actuar como humanos y alcanzar objetivos mediante la ejecución de una serie de tareas. Sin embargo, hasta el momento, estos robots no superan en rendimiento a las personas.

¿Qué elementos intervienen en el aprendizaje de un concepto?

Como anteriormente se ha expuesto, el programa de ordenador aprende en base a una experiencia E, que podría ser una base de datos de información sobre transacciones bancarias o una secuencia de imágenes, tal y como se ha visto en los anteriores ejemplos.

Cada una de estas imágenes o cada una de las transacciones que forman parte de la experiencia son denominadas **instancias**.

Una **instancia** es una ilustración específica de un objeto, símbolo, evento, proceso o procedimiento (Merrill, 1994).

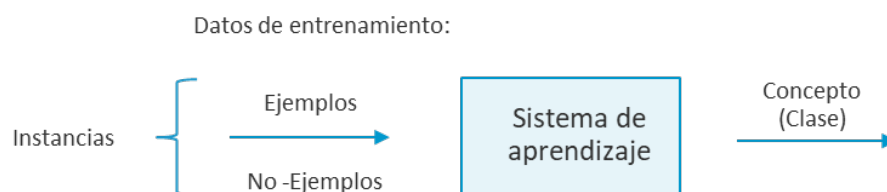


Figura 2. Entradas y salidas de un sistema de aprendizaje.

Como anteriormente se ha definido, el concepto será un conjunto de estas instancias que comparten ciertas características. A estas características se les denomina habitualmente **atributos**. Nótese que la mayoría de las palabras de nuestro idioma se refieren a categorías o clase de objetos y no a los objetos específicos únicos (por ejemplo: perro, gato, mesa, etc.). Al concepto habitualmente se le denomina **clase**. El concepto se puede aprender tanto a partir de instancias que pertenecen a la clase, como a partir de instancias que no pertenecen a la misma.

Por ejemplo, si queremos aprender a detectar usos fraudulentos de tarjetas podemos utilizar tanto datos de transacciones pertenecientes a aquellas habituales de cada cliente como datos de transacciones fraudulentas. Por tanto, la instancia es un término que se refiere tanto a miembros como a no-miembros de una clase.

En el ejemplo previo, las instancias son todas las transacciones registradas en la base de datos. Las instancias que son miembros del concepto en consideración se denominan **ejemplos**, mientras que las que no son miembros se denominan **no-ejemplos** (ver Figura 2). Por ejemplo, si queremos detectar usos fraudulentos a partir de describir las transacciones legales, los ejemplos serán aquellas transacciones legales mientras que los no-ejemplos serán las transacciones no legales.

El conjunto de instancias que forman parte de la experiencia E, que utiliza el sistema para aprender la tarea T, tanto ejemplos como no ejemplos, recibe el nombre de **datos de entrenamiento**.

¿En qué consiste aprender un concepto?

Se aprende un concepto cuando, dado un objeto (símbolo o evento), se puede identificar correctamente el concepto o clase a la que pertenece ese objeto, pudiéndose generalizar la aplicación del nombre de la clase a todos los miembros de esta y discriminando a los miembros que pertenecen a otra clase.

De esta afirmación obtenemos tres nuevos términos, utilizados habitualmente en el

aprendizaje automático:

- ▶ **Clasificación:** identificar la clase de un símbolo específico, objeto o evento; también identificar símbolos, objetos o eventos que no son miembros de una clase
- ▶ **Generalización:** identificar la clase de una instancia desconocida examinando atributos comunes de esa instancia con ejemplos encontrados previamente de esa clase.
- ▶ **Discriminación:** el hecho contrario a generalizar, esto es, dada una instancia desconocida, identificarla como no-miembro de la clase dado que no se encuentran atributos comunes con ejemplos previos de la clase.

En la Figura 3 se muestra un ejemplo muy sencillo. Una vez aprendido el concepto de «animal salvaje», se puede clasificar un animal a priori de clase desconocida dentro de la clase «animal salvaje» dados sus atributos (ej. «el animal vive en la jungla») — **generalización** — y se es capaz de discriminar un animal que no es salvaje por sus atributos (ej. «el animal es criado en una granja») — **discriminación**.

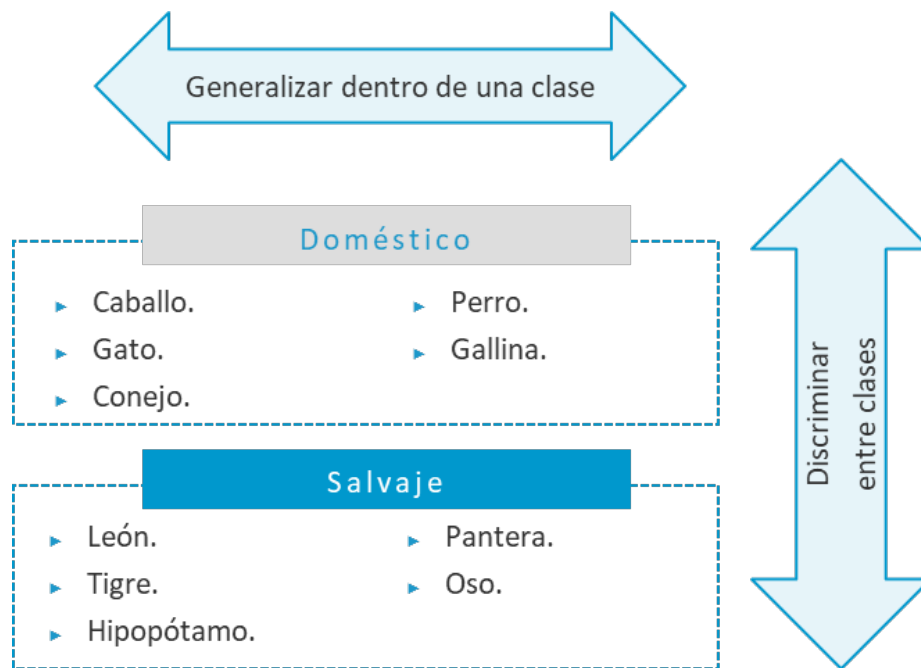


Figura 3. Ejemplo de generalización y discriminación de clases.

Mediante el aprendizaje se pueden resolver diferentes tipos de tareas básicas como la **descripción de conceptos** o la **formación de nuevos conceptos**. Si se ha aprendido el concepto de animal doméstico en base a los atributos de ejemplos bien conocidos de animales domésticos, se habla de una tarea de descripción de conceptos. A este tipo de aprendizaje se le denomina **aprendizaje supervisado**. Sin embargo, cuando en base a unos ejemplos se quiere aprender un nuevo concepto desconocido que los describa, esto es, formar un nuevo concepto, se habla de un **aprendizaje no-supervisado**.

El aprendizaje visto como una búsqueda

El aprendizaje de conceptos se plantea a menudo como una búsqueda en un espacio de posibles hipótesis (esto es, posibles soluciones al problema de aprendizaje) con el fin de encontrar la hipótesis que mejor encaje con los datos de entrenamiento. En este aprendizaje inductivo se puede garantizar que la hipótesis encontrada es la que mejor encaja con los datos de entrenamiento, pero ¿encajará

esa hipótesis también con nuevas instancias? Se asume que sí y se plantea, por tanto, la siguiente hipótesis:

Hipótesis del aprendizaje inductivo de conceptos

Cualquier hipótesis que encaje «suficientemente» bien con un conjunto <<suficientemente» grande de ejemplos de entrenamiento también encajará bien con instancias nuevas.

Esta hipótesis del aprendizaje inductivo permite la generalización. La dificultad está en determinar el espacio de hipótesis posibles en un problema de tal forma que se evite dejar fuera del espacio a la mejor hipótesis. Igualmente puede ser difícil determinar el tamaño de este espacio adecuado, así como el tamaño del conjunto de datos de entrenamiento requerido, de tal manera que se pueda generalizar la solución. Surge aquí el término «**bias**» inductivo.

El bias se refiere a los criterios de selección de las hipótesis y aquellos supuestos y suposiciones que se realizan para generalizar la mejor hipótesis encontrada.

Realísticamente hablando, en muchos problemas se pueden encontrar diferentes posibles descripciones de un concepto que encajan «razonablemente bien» con los datos. Por tanto, se trata de encontrar la que mejor encaja respecto a algún criterio, como la simplicidad. En muchas ocasiones no es viable realizar una búsqueda por un espacio de hipótesis completo, no pudiéndose garantizar, por tanto, que la hipótesis encontrada es la mejor y hay que determinar el probablemente mejor procedimiento de búsqueda de soluciones para el determinado problema.

Por otra parte, en la búsqueda de las mejores hipótesis en base a los datos de entrenamiento, muchas veces se encuentran soluciones demasiado específicas, que cubren de manera muy exacta los datos de entrenamiento. Esto puede generar un problema de **sobreajuste** (*overfitting*), siendo la solución adoptada demasiado específica respecto a los datos de entrenamiento y no se generaliza bien.

Habitualmente, para detectar el posible sobreajuste, se reserva un porcentaje de instancias del conjunto de partida que no intervienen en el entrenamiento, sino que, una vez encontrada la mejor hipótesis se utilizan para corroborar que la generalización de la solución es posible.

Sobre diversos *bias*, el problema del sobreajuste y cómo solucionarlo, se irá profundizando a lo largo de la asignatura, en el estudio de diversas técnicas de aprendizaje automático.

Aprendizaje supervisado

Un niño aprende conceptos viendo ejemplos de esos conceptos, ya sean perros, niños, niñas, mesas o coches. Los niños buscan características (atributos) comunes en, por ejemplo, los diferentes ejemplos denominados «perro» por los adultos.

Analizando estas características comunes, el niño es capaz de clasificar correctamente nuevas instancias que se encuentra de la clase «perro», sea cual sea la raza del perro. El niño ha creado un modelo de clasificación en base a ejemplos de perros clasificados por los adultos, examinando aquellos atributos que definen la clase. Este tipo de aprendizaje se denomina aprendizaje supervisado.

El **aprendizaje supervisado** pretende caracterizar o describir un concepto a partir de instancias del mismo.

El aprendizaje supervisado suele tener dos etapas, tal y como vemos en la Figura 4.

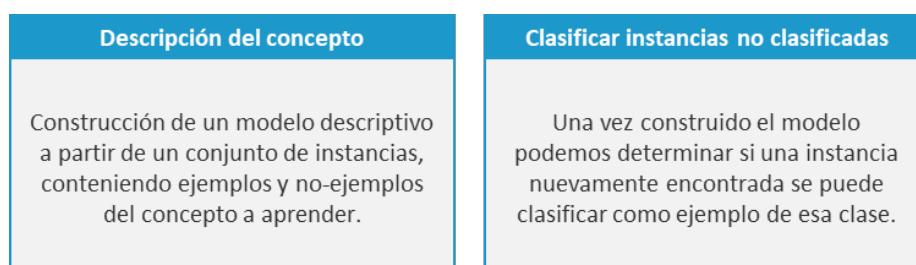


Figura 4. Etapas del aprendizaje supervisado.

Este tipo de aprendizaje es típicamente utilizado para diagnosticar enfermedades. En la Tabla 1 se muestra una base de datos de un centro médico a modo de ejemplo. En la primera fila se muestran los nombres de los atributos. «Número de paciente», «Fiebre», «Dolor de garganta», «Congestión» y «Dolor de cabeza» corresponden a los atributos de entrada y se refieren a los distintos síntomas presentados por los pacientes que han sido diagnosticados de distintas enfermedades. La columna «Diagnóstico» es el atributo de salida o clase, que quiere ser descrito en base a las instancias (datos o atributos de pacientes que ya han acudido a consulta) con el fin de poder predecir el diagnóstico de futuros pacientes en función de los valores de sus atributos de entrada (síntomas).

Número de paciente	Fiebre	Dolor de garganta	Congestión	Dolor de cabeza	Diagnóstico
1	Sí	Sí	No	Sí	Infección de garganta
2	No	No	Sí	No	Alergia
3	No	No	Sí	Sí	Resfriado
4	No	No	Sí	No	Alergia
5	Sí	Sí	Sí	Sí	Infección de garganta
6	No	No	Sí	No	Resfriado
7	Sí	No	Sí	Sí	Resfriado
8	Sí	Sí	No	Sí	Infección de garganta
9	No	No	Sí	Sí	Resfriado

Tabla 1. Ejemplo de base de datos para el diagnóstico de enfermedades. Fuente: elaboración propia.

Tomando los ejemplos de la , en primer lugar se pretende describir las diferentes clases (diagnósticos) aplicando una técnica de aprendizaje automático, como por ejemplo la denominada «árbol de decisión», así como obtener una representación como la mostrada en la , que representa una generalización de los datos de la Tabla 1.

Los datos de los pacientes 1 a 9, utilizados para crear el modelo expuesto en el árbol de decisión, corresponden a los **datos de entrenamiento**. Se suele utilizar unos **datos de prueba** también, cuya clasificación es bien conocida para verificar si la clasificación modelada se puede generalizar. En el siguiente tema se profundizará en estos nuevos conceptos. En este ejemplo concreto se han utilizado los datos de los 9 pacientes como datos de entrenamiento y se ha ejecutado el algoritmo de construcción de árboles de decisión ID3 (con la herramienta [Weka](#)) que se explicará en un tema posterior. Como se puede observar en la Figura 5, esta representación en árbol es muy fácil de interpretar por las personas, dado que es visualmente muy intuitiva, ayudando además el hecho de ser un ejemplo muy sencillo.

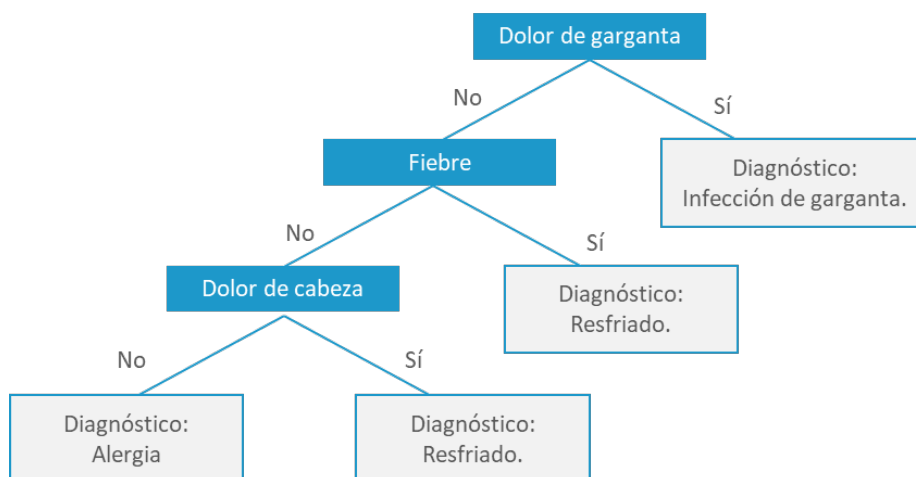


Figura 5. Árbol de decisión correspondiente a los datos de la Tabla 1.

Estos árboles de decisión son fácilmente trasladables a reglas de clasificación, representación igualmente muy intuitiva, como las que siguen:

SI “Dolor de garganta”=Sí

ENTONCES Diagnóstico=“Infección de garganta”

SI “Dolor de garganta”=No AND “Fiebre”=Sí

ENTONCES Diagnóstico=“Resfriado”

SI “Dolor de garganta”=No AND “Fiebre”=No AND “Dolor de cabeza”=Sí

ENTONCES Diagnóstico=“Resfriado”

SI “Dolor de garganta”=No AND “Fiebre”=No AND “Dolor de cabeza”=No

ENTONCES Diagnóstico=“Alergia”

Cuando llegan nuevos pacientes a la consulta cuyos datos se exponen en la Tabla 2 se podrá predecir la clase en base a la generalización expuesta en el árbol de decisión o en las reglas previamente indicadas.

Número de paciente	Fiebre	Dolor de garganta	Congestión	Dolor de cabeza	Diagnóstico
10	Sí	No	Sí	Sí	¿?
11	No	No	Sí	No	¿?

Tabla 2. Datos de atributos de entrada (síntomas) de nuevos pacientes.

Así, el paciente número 10 se le diagnostica «Resfriado» mientras que al número 11 se le diagnostica «Alergia». Se trata de un ejemplo muy sencillo con un número de instancias muy bajo, cuyo objetivo ha sido únicamente ilustrar en qué consiste el aprendizaje supervisado. En este ejemplo, el atributo «Número de Paciente» fue eliminado como dato de entrada, ya que no aporta información relevante. Por otra parte, el atributo «congestión» ha sido eliminado por el propio algoritmo de aprendizaje, dado que es un atributo no considerado relevante en la clasificación del diagnóstico.

Aprendizaje no-supervisado

El aprendizaje no-supervisado pretende caracterizar un concepto desconocido a partir de instancias de este. En este caso no existen clases definidas y por tanto se trata de describir un nuevo concepto o clase.

Las técnicas de **agrupamiento o clustering** son muy utilizadas en problemas de aprendizaje no-supervisado. Mediante *clustering* las instancias se agrupan de acuerdo con un esquema de similitud. En este tipo de aprendizaje, el no-supervisado, los datos de entrenamiento no especifican qué se está intentando aprender (los agrupamientos), mientras que, en el aprendizaje supervisado, las clases que se están intentando describir sí están especificadas.

El **clustering** se puede utilizar para el **análisis de datos** como un primer paso en la construcción de un modelo de estos. El algoritmo de *clustering* típicamente proporciona visualizaciones como la expuesta en la Figura 6, a partir de las cuales se pueden encontrar atributos similares en las instancias y tratar de extraer conclusiones.

Por ejemplo, en una investigación de mercado las técnicas de agrupamiento pueden ser muy útiles porque permiten agrupar a los consumidores, examinar propiedades comunes de los distintos grupos, que permitan obtener pistas o conclusiones con el fin de posicionar un producto, segmentar mercado, etc.

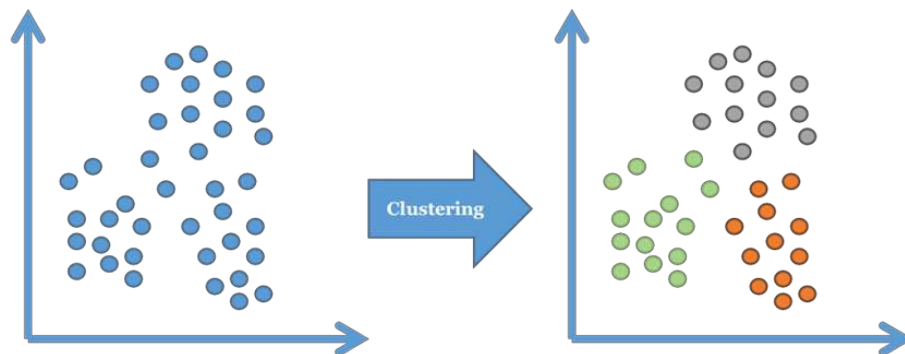


Figura 6. Ilustración ejemplo de aplicación de clustering a un conjunto de datos.

El *clustering* se puede utilizar además en **tareas de generalización**, descubriendo instancias similares, que comparten propiedades, y pudiendo incorporar futuras instancias en los agrupamientos generados.

Por ejemplo, un sistema de aprendizaje *online* puede utilizar una técnica de *clustering* para agrupar alumnos con atributos similares con el fin de, analizado el posible significado de los valores de estos atributos, proporcionarles estrategias de enseñanza adecuadas. Cuando un nuevo alumno se incorpora al sistema y hay datos disponibles, se le incorpora al agrupamiento donde se encuentran los otros alumnos más similares a él, y se le aplican las mismas estrategias de enseñanza.

¿Qué etapas comprende el aprendizaje de un concepto?

La Figura 7 muestra las etapas de aprendizaje de un concepto que se describen a continuación.

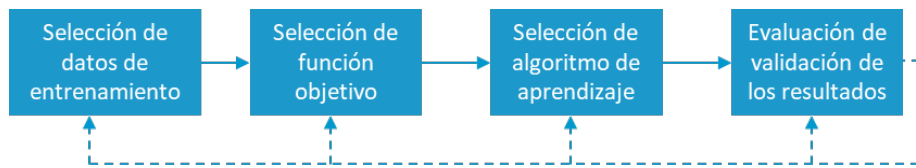


Figura 7. Etapas del aprendizaje de un concepto

Selección del conjunto de datos de entrenamiento

Como previamente se ha descrito, la computadora aprende de una experiencia, reflejada en un conjunto de instancias. La primera etapa para diseñar un sistema de aprendizaje consiste en analizar los datos existentes y seleccionar los datos de entrenamiento. Estos datos de entrenamiento pueden determinar crucialmente el éxito de la tarea de aprendizaje.

La cantidad de instancias disponibles o su relación con el concepto puede ser determinante. Evidentemente, cuanto mayor sea el número de instancias más fácil será la tarea de aprendizaje. Por otra parte, existen datos de entrenamiento que no proveen de una retroalimentación directa al sistema sobre la clase a aprender. Por ejemplo, si una máquina trata de aprender a jugar al ajedrez y cada movimiento realizado es una instancia, se tiene una **retroalimentación directa** si la clase indica si el movimiento es correcto para cada instancia. Sin embargo, si para un movimiento determinado (instancia), solo se tiene información de que ese movimiento corresponde a una serie de movimientos que dieron lugar a una partida que se ganó, la retroalimentación es indirecta.

En este caso la corrección del movimiento se infiere del hecho de que la partida se ganó, pero en realidad todos los movimientos realizados al ganar una partida no tienen por qué ser los correctos u óptimos en el momento en que fueron realizados. En este último caso sería conveniente asignar un factor de confianza que especifique cuánto puede haber influido un movimiento al éxito final de la partida, factor bastante difícil de determinar. Por tanto, el aprendizaje a partir de instancias que proveen

retroalimentación indirecta sobre la clase a aprender es más difícil.

Selección de una función objetivo y su representación

En la siguiente etapa se ha de determinar el tipo de conocimiento que se va a aprender, se trata de determinar una función objetivo y representarla. Una vez representado el problema en una función objetivo, la mejora del rendimiento P en una tarea T se reduce al aprendizaje de una determinada función objetivo. Para el aprendizaje del ajedrez, esta función podría consistir en una función que asigna un determinado número a cada movimiento de los movimientos legales posibles, asignando un número mayor a aquellos movimientos que producen mejores posiciones de tablero.

En el ejemplo mostrado en la explicación previa de aprendizaje supervisado se busca aprender una función que, tomando como entrada valores discretos, produce una salida igualmente discreta con tres valores correspondientes a los tres posibles diagnósticos. La función que aprender es una disyunción de conjunciones lógicas de condiciones de los valores de entrada y puede ser representada mediante un árbol de decisión o un conjunto de reglas del tipo SI-ENTONCES.

En el árbol inducido cada camino desde la raíz a las hojas corresponde a una conjunción de condiciones y el propio árbol engloba la disyunción de las conjunciones. La función expresada como árbol está en la Figura 5 mientras que, en forma de reglas, empleando las conjunciones lógicas AND y OR quedaría de la siguiente manera:

SI "Dolor de garganta"=Sí

ENTONCES Diagnóstico="Infección de garganta"

SI ("Dolor de garganta"=No AND "Fiebre"=Sí) OR ("Dolor de garganta"=No AND "Fiebre"=No AND "Dolor de cabeza"=Sí)

ENTONCES Diagnóstico="Resfriado"

SI "Dolor de garganta"=No AND "Fiebre"=No AND "Dolor de cabeza"=No

ENTONCES Diagnóstico="Alergia"

Selección del algoritmo de aprendizaje para aproximación a la función objetivo

Una vez se conoce el conjunto de entrenamiento y la función objetivo, se debe escoger un algoritmo de aproximación a la función objetivo. En el ejemplo de aprendizaje supervisado, dado que la función se va a representar como un árbol, es lógico escoger un método de construcción de árboles de decisión. Existen diversos métodos para el aprendizaje de árboles y la selección de uno u otro dependerá de diversos factores como si, por ejemplo, las entradas toman valores discretos o continuos, si existen datos ruidosos, etc.

Evaluación y validación de los resultados

Escoger una buena función objetivo o un algoritmo adecuado para una tarea de aprendizaje concreta puede resultar en una tarea complicada. Por tanto, en la etapa de evaluación los resultados podrían no ser los esperados. Por tanto, en la etapa de evaluación hay que considerar si es necesario regresar a un paso previo o validar el aprendizaje realizado. Así el problema de aprendizaje de un concepto puede resultar en un proceso cíclico hasta obtener los resultados deseados.

1.4. Etapas en el descubrimiento de conocimiento

El aprendizaje implica extraer y ampliar el conocimiento y, desde este punto de vista, se puede ver el objetivo de la minería de datos como un intento por modelar el conocimiento, convirtiendo información no estructurada en conocimiento. De aquí surge el término **Ingeniería de Conocimiento** que versa sobre el proceso de construir un sistema inteligente para obtener conocimiento.

En el marco del máster actual ser capaz de aplicar técnicas de IA para descubrir conocimiento en bases de datos es de gran interés, es lo que se ha definido anteriormente como minería de datos. El término **Descubrimiento de Conocimiento en Bases de Datos**, en inglés *Knowledge Discovery in Databases (KDD)*, es frecuentemente utilizado como sinónimo de la minería de datos (Fayyad, 2001; Fayyad *et al.*, 1996).

Sin embargo, este término se refiere al **procedimiento completo** necesario para extraer conocimiento potencialmente útil y previamente desconocido a partir de los datos en una base de datos (Roiger, 2003). KDD es un proceso iterativo que incluye etapas previas a la fase de minería de datos propiamente dicha, para la extracción y preparación de los datos, así como etapas posteriores para el análisis de los resultados y toma de decisiones.

Hay diferentes modelos KDD definidos, pero sea cual sea el modelo KDD utilizado, el **primer paso** siempre consistirá en **identificar el objetivo de la aplicación** del procedimiento, esto es, definir el problema identificando la tarea que se ha de realizar, estableciendo hipótesis sobre los resultados deseados y posibles.

El resto de las etapas variará de unos modelos a otros, aunque típicamente se establecerán las siguientes etapas representadas en la Figura 8 (Han & Kamber, 2012; Roiger, 2003):

- ▶ **Integración de los datos:** en la Figura 8 se representa un caso en el que hay múltiples fuentes de datos que pueden ser combinadas y, por tanto, es necesario un primer paso de integración de los datos.
- ▶ **Selección de los datos:** se debe escoger un conjunto de datos considerados relevantes que serán analizados. Esta selección debe ser realizada por personas expertas en el dominio en cuestión o mediante la ayuda de herramientas de descubrimiento de conocimiento. En el ejemplo previo de base de datos sobre síntomas y diagnósticos de enfermedades (Tabla 1) es evidente que el atributo «Número de paciente» no es relevante en el análisis. Sin embargo, la eliminación de atributos de entrada no es siempre tan evidente y se han de utilizar técnicas específicas para ello.
- ▶ **Pre-procesamiento de los datos:** los datos ruidosos y datos inconsistentes son tratados. Por ejemplo, una base de datos puede contener datos duplicados, valores incorrectos o desconocidos. Se pueden utilizar métodos automáticos estadísticos como la aplicación de *outliers* (por ejemplo, eliminar el 5 % de los valores más lejanos a la predicción). Este paso es denominado limpieza de datos por algunos autores y requiere conocer muy bien los datos, habiendo un riesgo de descartar de ejemplos de clases poco frecuentes.
- ▶ **Transformación de los datos:** los datos son normalizados y convertidos si es necesario. Por ejemplo, algunos métodos de minería de datos no pueden procesar datos nominales por lo que se han de convertir los datos nominales a numéricos. Igualmente hay métodos que son mucho más lentos con atributos numéricos que con nominales por lo que se han de discretizar los valores de los atributos de entrada.
- ▶ **Minería de datos.** Se ejecutan técnicas de inteligencia artificial para extraer

patrones en los datos.

- **Interpretación y evaluación de los resultados.** Se examina la salida del paso anterior para determinar si los datos descubiertos son útiles e interesantes. A partir de aquí hay que tomar la decisión de si repetir los pasos previos usando nuevos atributos o instancias. Se pueden utilizar técnicas de visualización y representación de conocimiento en esta etapa para facilitar la tarea.

Una vez se concluye que el conocimiento descubierto es útil, se aplica ese conocimiento al problema apropiado. Esta etapa puede servir para verificar las conclusiones extraídas en la etapa de interpretación de resultados.

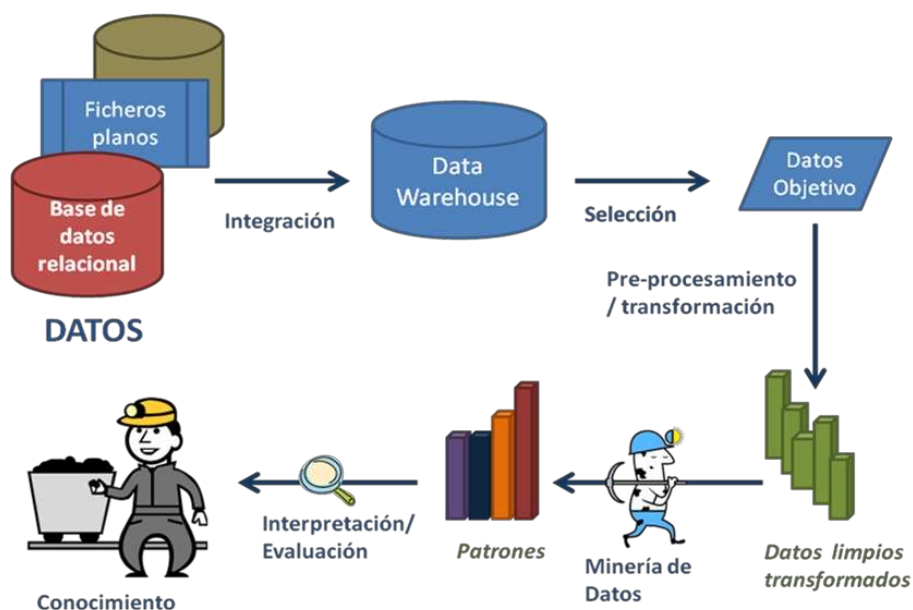


Figura 8. Etapas de un procedimiento típico KDD.

1.5. Referencias bibliográficas

Abduljabbar, R., Dia, H., Liyanage, S. & Bagloee, S. A. (2019). Applications of Artificial Intelligence in Transport: An Overview. *Sustainability*, 11(1), 189. Disponible en

<https://doi.org/10.3390/su11010189>

Aguado, F., Cabalar, P., Fandinno, J., Muñiz, B., Pérez, G. & Suárez, F. (2019). A Rule-Based System for Explainable Donor-Patient Matching in Liver Transplantation. *Electronic Proceedings in Theoretical Computer Science*, 306, 266-272. Disponible en

<https://doi.org/10.4204/EPTCS.306.31>

Akinnola, B. (2012). *Computer Troubleshooting, Using an Expert System: A Research Work*. LAP Lambert Academic Publishing.

Alonso, R. S., Prieto, J., García, Ó. & Corchado, J. M. (2019). Collaborative learning via social computing. *Frontiers of Information Technology & Electronic Engineering*, 20(2), 265-282. Disponible en <https://doi.org/10.1631/FITEE.1700840>

Alonso, R. S., Sittón-Candanedo, I., García, Ó., Prieto, J. & Rodríguez-González, S. (2020). An intelligent Edge-IoT platform for monitoring livestock and crops in a dairy farming scenario. *Ad Hoc Networks*, 98, 102047. Disponible en

<https://doi.org/10.1016/j.adhoc.2019.102047>

ASALE, R. & RAE. (s. f.). Inteligencia | Diccionario de la lengua española. «Diccionario de la lengua española». Edición del Tricentenario. Recuperado de

<https://dle.rae.es/inteligencia>

Bayram, B. & Ince, G. (2018). Advances in Robotics in the Era of Industry 4.0. En A. Ustundag & E. Cevikcan (Eds.), *Industry 4.0: Managing The Digital Transformation* (pp. 187-200). Springer International Publishing. Disponible en

https://doi.org/10.1007/978-3-319-57870-5_11

Boru, A., Dosdoğru, A. T., Göçken, M. & Erol, R. (2019). A Novel Hybrid Artificial Intelligence Based Methodology for the Inventory Routing Problem. *Symmetry*, 11(5), 717. Disponible en <https://doi.org/10.3390/sym11050717>

Cevik Onar, S. & Ustundag, A. (2018). Smart and Connected Product Business Models. En A. Ustundag & E. Cevikcan (Eds.), *Industry 4.0: Managing The Digital Transformation* (pp. 25-41). Springer International Publishing. Disponible en https://doi.org/10.1007/978-3-319-57870-5_2

Davis, D. S. (2020). Geographic Disparity in Machine Intelligence Approaches for Archaeological Remote Sensing Research. *Remote Sensing*, 12(6), 921. Disponible en <https://doi.org/10.3390/rs12060921>

Elmishali, A., Stern, R. & Kalech, M. (2018). An Artificial Intelligence paradigm for troubleshooting software bugs. *Engineering Applications of Artificial Intelligence*, 69, 147-156. Disponible en <https://doi.org/10.1016/j.engappai.2017.12.011>

Farooq, A., Anwar, S., Awais, M. & Alnowami, M. (2017). Artificial intelligence based smart diagnosis of alzheimer's disease and mild cognitive impairment. *2017 International Smart Cities Conference (ISC2)*, 1-4. Disponible en

<https://doi.org/10.1109/ISC2.2017.8090871>

Fayyad, U. (2001). Knowledge Discovery in Databases: An Overview. En S. Džeroski & N. Lavrač (Eds.), *Relational Data Mining* (pp. 28-47). Springer. Disponible en https://doi.org/10.1007/978-3-662-04599-2_2

Fayyad, U., Piatetsky-Shapiro, G. & Smyth, P. (1996). From Data Mining to Knowledge Discovery in Databases. *AI Magazine*, 17(3), 37-37. Disponible en

<https://doi.org/10.1609/aimag.v17i3.1230>

García, Ó., Alonso, R., Prieto, J., & Corchado, J. (2017). Energy Efficiency in Public Buildings through Context-Aware Social Computing. *Sensors*, 17(4), 826. Disponible en <https://doi.org/10.3390/s17040826>

García, Ó., Alonso, R. S., Tapia, D. I. & Corchado, J. M. (2015). CAFCLA: A framework to design, develop, and deploy AMI-based collaborative learning applications. En *Recent advances in ambient intelligence and context-aware computing* (pp. 187–209). IGI Global.

Han, J. & Kamber, M. (2012). *Data mining: Concepts and techniques* (3rd ed). Elsevier.

Jain, A., Shah, D. & Churi, P. (2020). A Review on Business Intelligence Systems Using Artificial Intelligence. En S. Smys, J. M. R. S. Tavares, V. E. Balas, & A. M. Iliyasu (Eds.), *Computational Vision and Bio-Inspired Computing* (pp. 1023-1030). Springer International Publishing. Disponible en https://doi.org/10.1007/978-3-030-37218-7_107

Joshi, A. V. (2020). Recommendations Systems. En A. V. Joshi (Ed.), *Machine Learning and Artificial Intelligence* (pp. 199-204). Springer International Publishing. Disponible en https://doi.org/10.1007/978-3-030-26622-6_21

Jozí, A., Pinto, T., Marreiros, G., & Vale, Z. (2019). *Electricity consumption forecasting in office buildings: An artificial intelligence approach*. 2019 IEEE Milan PowerTech, 1-6. Disponible en <https://doi.org/10.1109/PTC.2019.8810503>

Jozí, A., Pinto, T., Praça, I., Silva, F., Teixeira, B. & Vale, Z. (2017). Energy consumption forecasting using genetic fuzzy rule-based systems based on MOGUL

learning methodology. *2017 IEEE Manchester PowerTech*, 1-5. Disponible en

<https://doi.org/10.1109/PTC.2017.7981219>

Khine, P. P. & Wang, Z. S. (2018). Data lake: A new ideology in big data era. *ITM Web of Conferences*, 17, 03025. Disponible en

<https://doi.org/10.1051/itmconf/20181703025>

Liakos, K. G., Busato, P., Moshou, D., Pearson, S. & Bochtis, D. (2018). Machine Learning in Agriculture: A Review. *Sensors*, 18(8), 2674. Disponible en

<https://doi.org/10.3390/s18082674>

Linden, G., Smith, B., & York, J. (2003). Amazon.com recommendations: Item-to-item collaborative filtering. *IEEE Internet Computing*, 7(1), 76-80. Disponible en

<https://doi.org/10.1109/MIC.2003.1167344>

Malhotra, D. k., Nydick, R. L. & Malhotra, K. (2017). Evaluating bank solvency with support vector machines. *International Journal of Business Intelligence and Systems Engineering*, 1(2), 179-195. Disponible en

<https://doi.org/10.1504/IJBISE.2017.088698>

Mali, G. U. & Gautam, D. K. (2018). Shortest Path Evaluation in Wireless Network Using Fuzzy Logic. *Wireless Personal Communications*, 100(4), 1393-1404.

Disponible en <https://doi.org/10.1007/s11277-018-5645-1>

Matlou, O. G. & Abu-Mahfouz, A. M. (2017). Utilising artificial intelligence in software defined wireless sensor network. *IECON 2017 - 43rd Annual Conference of the IEEE Industrial Electronics Society*, 6131-6136. Disponible en

<https://doi.org/10.1109/IECON.2017.8217065>

McGovern, A., Elmore, K. L., Gagne, D. J., Haupt, S. E., Karstens, C. D., Lagerquist, R., Smith, T. & Williams, J. K. (2017). Using Artificial Intelligence to Improve Real-

Time Decision-Making for High-Impact Weather. *Bulletin of the American Meteorological Society*, 98(10), 2073-2090. Disponible en <https://doi.org/10.1175/BAMS-D-16-0123.1>

Merrill, M. D., Tennyson, R. D. & Posey, L. O. (1992). *Teaching concepts: An instructional design guide* (2nd ed). Educational Technology Publications.

Mitchell, T. M. (1997). *Machine Learning*. McGraw-Hill.

Mohammed, M. A., Abd Ghani, M. K., Hamed, R. I., Mostafa, S. A., Ahmad, M. S. & Ibrahim, D. A. (2017). Solving vehicle routing problem by using improved genetic algorithm for optimal solution. *Journal of Computational Science*, 21, 255-262. Disponible en <https://doi.org/10.1016/j.jocs.2017.04.003>

Namatevs, I. & Aleksejeva, L. (2017). Decision Algorithm for Heuristic Donor-Recipient Matching. *MENDEL*, 23(1), 33-40. Disponible en <https://doi.org/10.13164/mendel.2017.1.033>

Narasima, D. (2018). Industry 4.0: Reimagining the Future of Workplace (Five Business Case Applications of Artificial Intelligence, Machine Learning, Robots, Virtual Reality in Five Different Industries). *International Journal of Engineering, Business and Enterprise Applications (IJEBA)*, 26(1), 5-8. Disponible en <https://papers.ssrn.com/abstract=3303732>

Negnevitsky, M. (2005). *Artificial intelligence: A guide to intelligent systems* (2nd ed). Addison-Wesley.

Nushi, B., Kamar, E., Horvitz, E. & Kossmann, D. (2017, febrero 12). *On Human Intellect and Machine Failures: Troubleshooting Integrative Machine Learning Systems*. Thirty-First AAAI Conference on Artificial Intelligence. Thirty-First AAAI Conference on Artificial Intelligence. Disponible en

<https://www.aaai.org/ocs/index.php/AAAI/AAAI17/paper/view/15032>

Ohlsson, S., Sloan, R. H., Turán, G. & Urasky, A. (2017). Measuring an artificial intelligence system's performance on a Verbal IQ test for young children. *Journal of Experimental & Theoretical Artificial Intelligence*, 29(4), 679-693. Disponible en <https://doi.org/10.1080/0952813X.2016.1213060>

García, O, Prieto, J., Alonso, R. y Corchado, J. (2017). A Framework to Improve Energy Efficient Behaviour at Home through Activity and Context Monitoring. *Sensors*, 17(8), 1749. Disponible en <https://doi.org/10.3390/s17081749>

Pannu, A. (2015). Artificial Intelligence and its Application in Different Areas. *International Journal of Engineering and Innovative Technology*, 4(10), 79-84. Disponible en

http://www.ijeit.com/Vol%204/Issue%2010/IJEIT1412201504_15.pdf

Peng, M., Yang, J., Shi, Q., Ying, L., Zhu, H., Zhu, G., Ding, X., He, Z., Qin, J., Wang, J., Yan, H., Bi, X., Shen, B., Wang, D., Luo, L., Zhao, H., Zhang, C., Lin, Z., Hong, L. & Li, J. (2020). Artificial Intelligence Application in COVID-19 Diagnosis and Prediction. *Social Science Research Network*. Disponible en

<https://papers.ssrn.com/abstract=3541119>

Panesar, A. (2019). *What Is Machine Learning? In Machine Learning and AI for Healthcare* (pp. 75-118). Apress, Berkeley, CA.

Poole, D. L. & Mackworth, A. K. (2010). *Artificial intelligence: Foundations of computational agents*. Cambridge University Press.

Rogers, S. & Girolami, M. (2017). *A first course in machine learning* (Second Edition). CRC Press, Taylor & Francis Group, a Chapman & Hall book.

Roiger, R. J. (2003). *Data Mining: A Tutorial-Based Primer*. Addison Wesley.

Disponible en <https://www.crcpress.com/Data-Mining-A-Tutorial-Based-Primer-Second-Edition/Roiger/p/book/9781498763974>

Sami Sivri, M. & Oztaysi, B. (2018). Data Analytics in Manufacturing. En A. Ustundag & E. Cevikcan (Eds.), *Industry 4.0: Managing The Digital Transformation* (pp. 155-172). Springer International Publishing. Disponible en https://doi.org/10.1007/978-3-319-57870-5_9

Silva, J., Praça, I., Pinto, T., & Vale, Z. (2020). Energy Consumption Forecasting Using Ensemble Learning Algorithms. En E. Herrera-Viedma, Z. Vale, P. Nielsen, A. Martin Del Rey, & R. Casado Vara (Eds.), *Distributed Computing and Artificial Intelligence*, 16th International Conference, Special Sessions (pp. 5-13). Springer International Publishing. Disponible en https://doi.org/10.1007/978-3-030-23946-6_1

Sterne, J. (2017). *Artificial intelligence for marketing: Practical applications*. Wiley.

Traviglia, A. & Torsello, A. (2017). Landscape Pattern Detection in Archaeological Remote Sensing. *Geosciences*, 7(4), 128. Disponible en <https://doi.org/10.3390/geosciences7040128>

Turing, A. (1950). Computing machinery and intelligence. *Mind*, 59(236), 433.

Vinagre, E., De Paz, J. F., Pinto, T., Vale, Z., Corchado, J. M. & Garcia, O. (2016). *Intelligent energy forecasting based on the correlation between solar radiation and consumption patterns*. 2016 IEEE Symposium Series on Computational Intelligence (SSCI), 1-7. Disponible en <https://doi.org/10.1109/SSCI.2016.7849853>

Witten, I. H. & Frank, E. (2005). *Data mining: Practical machine learning tools and techniques* (2nd ed). Morgan Kaufman.

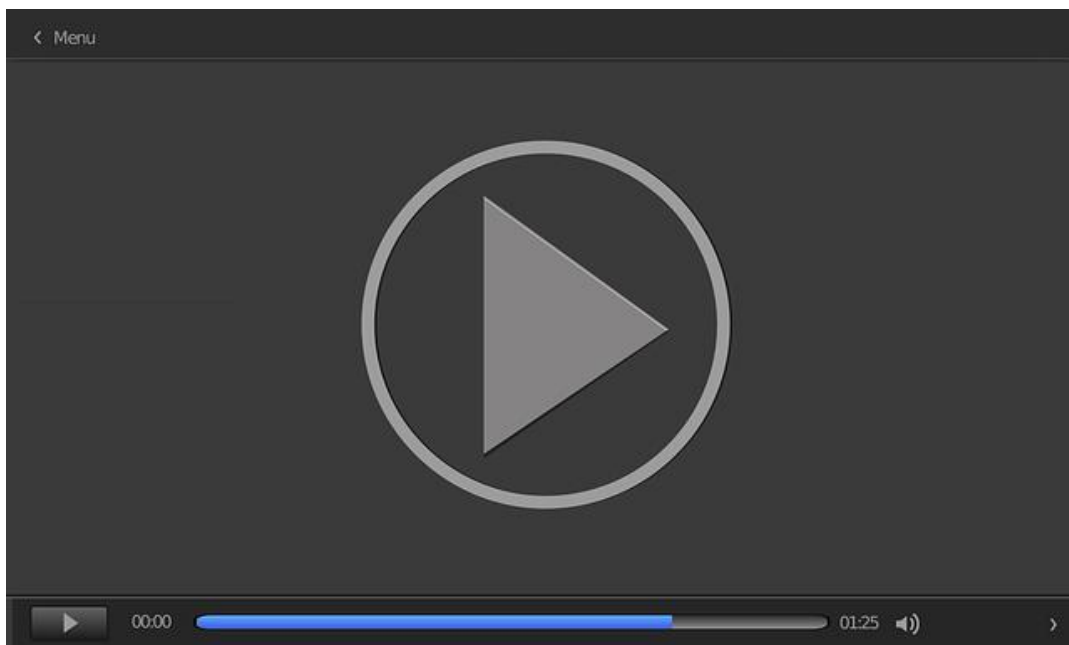
Zeeshan, M. & Saxena, K. (2020). Explorative Study of Artificial Intelligence in Digital Marketing. En A. P. Pandian, R. Palanisamy, & K. Ntalianis (Eds.), *Proceeding of the International Conference on Computer Networks, Big Data and IoT* (ICCBI - 2019)

(pp. 968-978). Springer International Publishing. Disponible en

https://doi.org/10.1007/978-3-030-43192-1_107

Introducción e historia de la inteligencia artificial

En esta lección magistral se relata la historia de la Inteligencia Artificial (IA), desde sus inicios en la 'era oscura', hasta los actuales sistemas basados en conocimiento. Se describen de forma resumida algunos de los hechos y personajes más relevantes de la IA, así como la motivación que lleva al surgimiento de alguna de las técnicas que serán estudiadas en posteriores temas de esta asignatura.



01. Introducción e historia de la inteligencia artificial

Accede al vídeo:

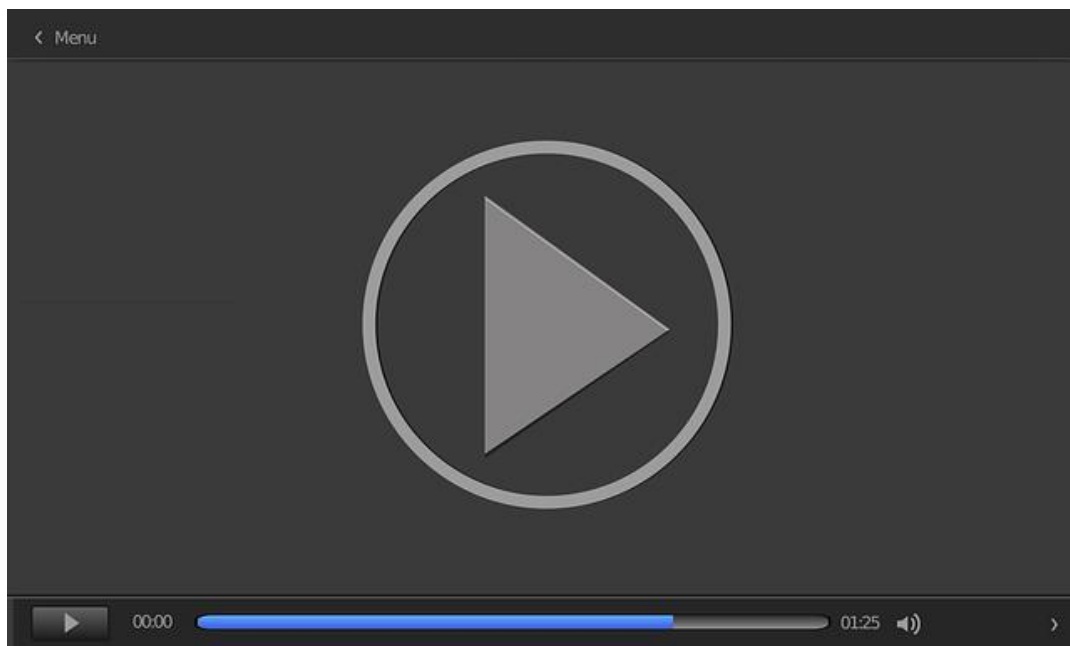
<https://unir.cloud.panopto.eu/Panopto/Pages/Embed.aspx?id=d6992430-08fe-4dfd-bbb4-aff800f9db84>

Entrevista a Matilde Santos Peñas sobre la inteligencia artificial

Accede al vídeo desde el aula virtual o a través de la siguiente dirección web:

https://www.youtube.com/watch?v=v_1aR6hha2k.

Matilde Santos Peñas, Catedrática de Universidad del área de Ingeniería de Sistemas y Automática en la Universidad Complutense de Madrid y coautora del libro «Inteligencia Artificial e Ingeniería del Conocimiento» de la editorial RA-MA, da una visión general muy didáctica e interesante de diversos aspectos de la inteligencia artificial, mencionando inquietudes personales, cuestiones y técnicas.



Accede al vídeo:

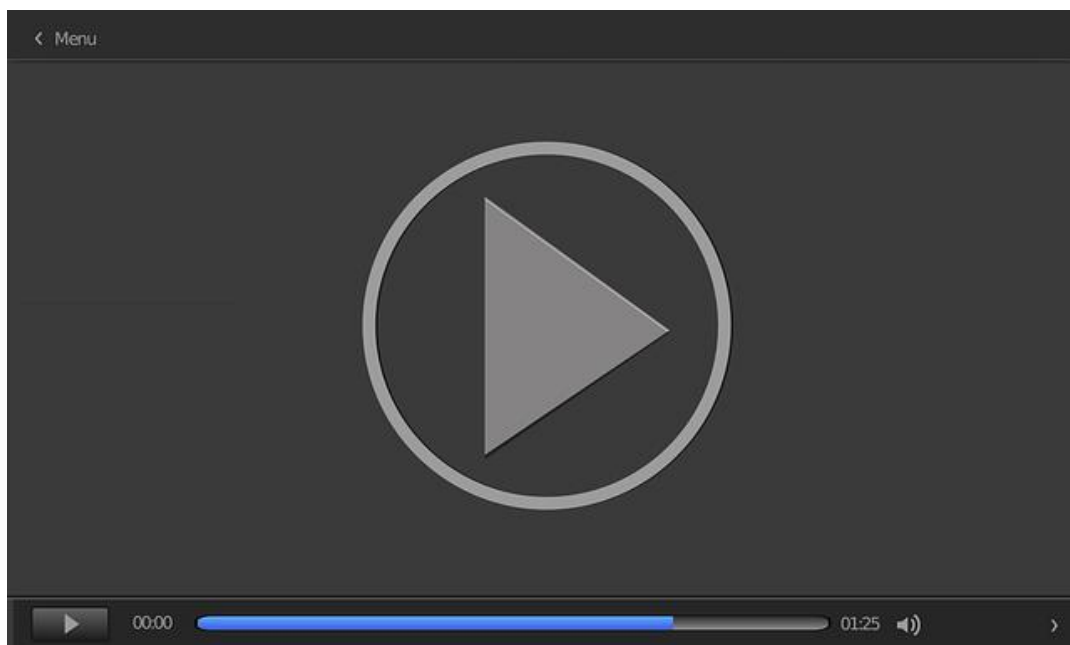
https://www.youtube.com/embed/v_1aR6hha2k

Conciencia artificial y test de Turing

Accede al vídeo desde el aula virtual o a través de la siguiente dirección web:

<https://www.youtube.com/watch?v=Y90a6Xwwh3w>

Extracto del programa Tres14 en el que Raúl Arrabales, ingeniero informático de la Universidad Carlos III de Madrid, habla sobre conciencia artificial y el test de Turing.



Accede al vídeo:

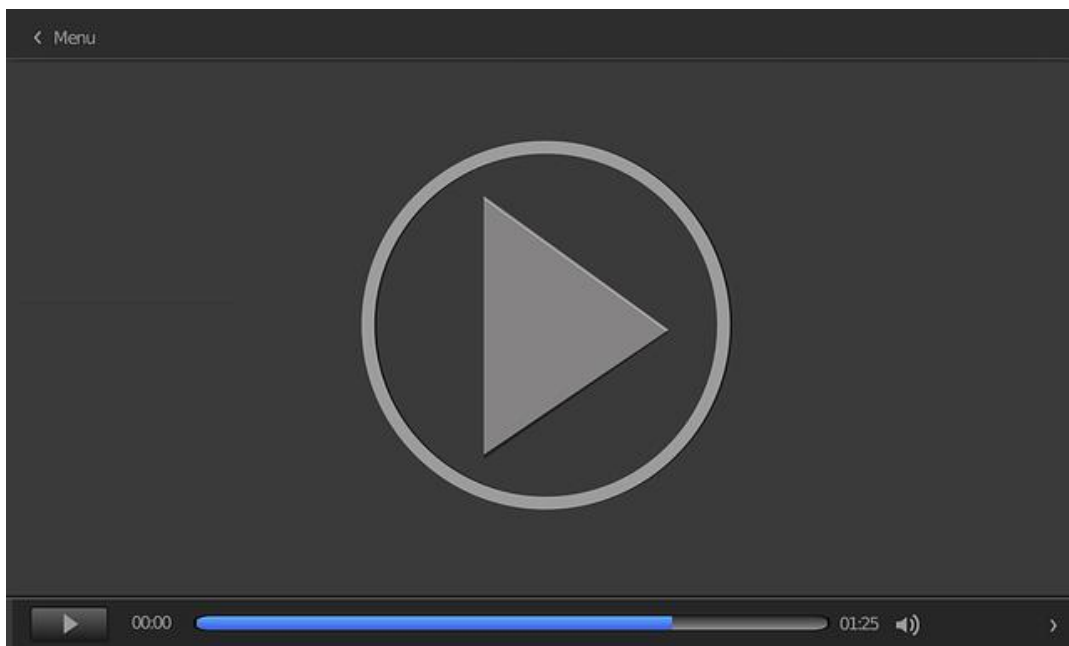
<https://www.youtube.com/embed/Y90a6Xwwh3w>

Inteligencia artificial

Accede al vídeo desde el aula virtual o a través de la siguiente dirección web:

https://www.youtube.com/watch?v=Ut6gDw_Onwk

Programa muy interesante, de casi media hora de duración, que describe diversas cuestiones y problemas de la inteligencia artificial, centrándose principalmente en la robótica.



Accede al vídeo:

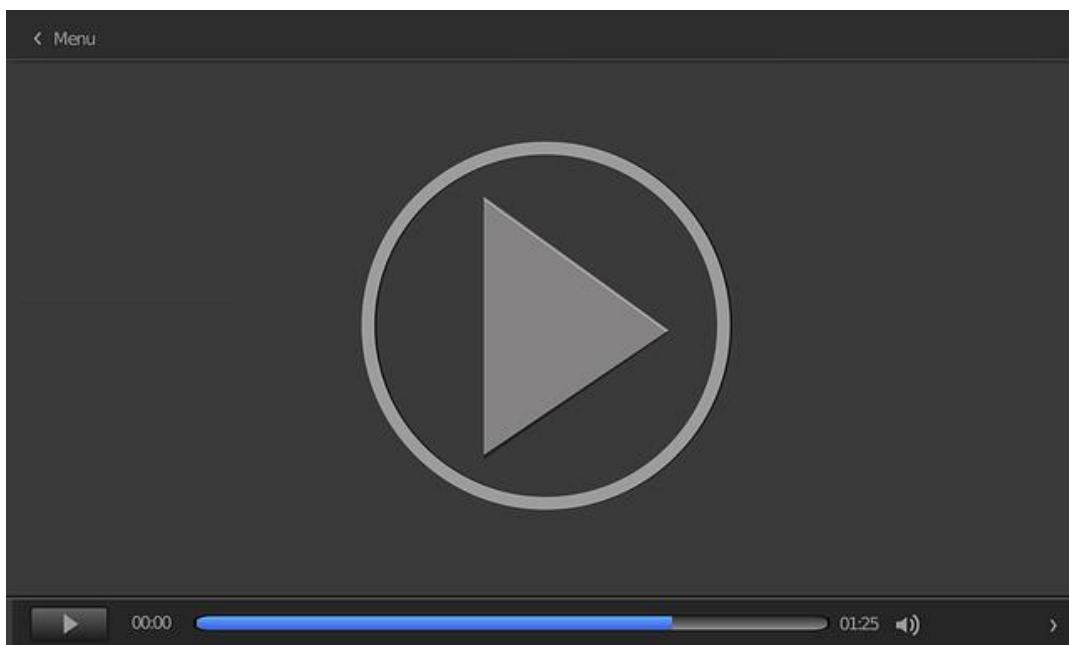
https://www.youtube.com/embed/Ut6gDw_Onwk

Presentación introductoria de la minería de datos

Accede al vídeo desde el aula virtual o a través de la siguiente dirección web:

<https://youtu.be/QY09nSg-KBk>

Presentación sobre la minería de datos que resume conceptos básicos pero relevantes en esta área de manera clara y sencilla.



Accede al vídeo:

<https://www.youtube.com/embed/QY09nSg-KBk>

AI Topics

Accede a la página desde el aula virtual o a través de la siguiente dirección web:
<http://aitopics.org/>.

AITopics.org es un sitio web que recopila información sobre la investigación y las aplicaciones de la inteligencia artificial. Contiene enlaces muy interesantes a vídeos, materiales para cursos, etc.

1. Indica cuáles de las siguientes afirmaciones son correctas:
 - A. La escuela de la Inteligencia Artificial Fuerte defiende que las máquinas pueden llegar a tener conciencia.
 - B. La escuela de la Inteligencia Artificial Débil no defiende que los procesos cerebrales puedan ser simulados en un computador.
 - C. El juego de imitación de Turing consiste en que una máquina consiga mantener una conversación tal y como lo haría un humano.
 - D. Las técnicas de aprendizaje automático no forman parte del campo de la inteligencia artificial.

2. Indica cuál de las siguientes afirmaciones no es correcta:
 - A. La minería de datos utiliza técnicas de aprendizaje automático para descubrir patrones en grandes cantidades de datos.
 - B. La minería de datos tiene un objetivo fundamentalmente teórico.
 - C. Existe una fase en los procedimientos KDD que consiste en ejecutar técnicas de inteligencia artificial.
 - D. En los procedimientos KDD, previo a la fase de minería de datos, se dan otras fases de selección y transformación de los datos.

3. Indica cuál de las siguientes afirmaciones no es correcta respecto a la experiencia en el aprendizaje de conceptos. La experiencia:
 - A. Consiste en un conjunto de objetos específicos denominados instancias.
 - B. Consiste en una serie de ejemplos y no-ejemplos.
 - C. Consiste en una serie de instancias con atributos de entrada y de salida.
 - D. Consiste en un conjunto de datos denominado datos de prueba.

4. Identificar la clase de una instancia desconocida en base a sus atributos, que se presentan comunes a ejemplos previos encontrados de esa clase es una tarea de:
- A. Discriminación.
 - B. Generalización.
 - C. Clasificación.
 - D. Descripción.
5. Una tarea de aprendizaje consiste en descubrir los síntomas comunes de un grupo de pacientes que presentan una enfermedad bien conocida. Se trata de un problema de aprendizaje de tipo:
- A. Supervisado.
 - B. No-supervisado.
6. Una tarea de aprendizaje consiste en descubrir los síntomas comunes de un grupo de pacientes con diagnóstico desconocido. Se trata de un problema de aprendizaje de tipo:
- A. Supervisado.
 - B. No-supervisado.
7. Indica cuál de las siguientes afirmaciones no es cierta, respecto al descubrimiento de conocimiento en bases de datos:
- A. Es un procedimiento completo necesario para extraer conocimiento a partir de los datos de una base de datos.
 - B. Sea cual sea el procedimiento KDD las fases siempre son las mismas.
 - C. La interpretación de los resultados forma parte del procedimiento KDD.
 - D. Es un proceso que puede ser iterativo.

8. Indica cuál de las siguientes afirmaciones no es correcta:
- A. Los datos de entrenamiento son un conjunto de instancias.
 - B. Los datos de entrenamiento pueden contener no-ejemplos.
 - C. Los atributos son denominados también ejemplos.
 - D. Al concepto que se aprende se le llama también clase.
 - E. El concepto es un conjunto de instancias.
9. Indica cuáles de las siguientes afirmaciones son correctas respecto al aprendizaje de conceptos:
- A. Los problemas de aprendizaje se resuelven a veces como una búsqueda en un espacio de hipótesis.
 - B. Siempre se aplican las técnicas de búsqueda de la mejor hipótesis sobre el espacio completo de posibles hipótesis.
 - C. El tamaño de los datos de entrenamiento no influye en el resultado del aprendizaje.
 - D. Se pueden encontrar en la práctica distintas descripciones de un concepto.
 - E. El sobreajuste consiste en generalizar demasiado.
10. Indica cuál de las siguientes frases no es correcta respecto a un sistema experto:
- A. Se incorpora en el sistema el conocimiento de un experto humano.
 - B. Raramente se ha aplicado un sistema experto a un problema real con éxito.
 - C. Suele estar limitado a un dominio de conocimiento.
 - D. Puede ser complementado con técnicas de aprendizaje automático como las redes neuronales para obtener reglas a partir de grandes cantidades de datos que el experto humano es incapaz de obtener.